

AI 客服系统 使用文档


本地一体化智能客服系统

核心能力

涵盖意图识别与专业路由、长期记忆、语义召回和治理，以及桌面工作台、运维诊断、模型网关和安全边界。

项目	说明
适用系统	Windows 10 / 11 64 位
服务渠道	个人微信、企业微信
运行方式	本机后端 + 桌面工作台 + 本机渠道 Hook
文档依据	当前项目代码、配置模板、启动脚本和工作台页面
修订日期	2026 年 8 月 12 日

适用对象：门店客服、运营人员、系统管理员、安装交付人员。实际文件名和安装包外观可能随交付方式变化，功能与配置以本项目目录中的文件为准。



目录 文档导航

章节	主要内容
一	系统定位、架构与三类信息边界
二	安装、首次启动与日常启动
三	模型、密钥、桌面工作台与发送配置
四	意图识别与安全路由
五	知识库维护、证据约束与选择性反哺
六	长期记忆的提取、召回、画像与治理
七	桌面工作台全部页面
八	个人微信、企业微信、实例与版本管理
九	日常接待、人工协同与消息投递
十	群发与群发任务
十一	后台管理、数据与运维工具
十二	首次验收、故障排查、安全与卸载

阅读建议

安装交付人员先看第二、三、十二章；客服和运营先看第四至第十章；系统管理员重点阅读第三、十一、十二章。

一 系统定位与工作原理

AI 客服系统在 Windows 本机一体运行，连接个人微信和企业微信，负责接收客户消息、识别本轮意图、检索可信知识、参考相关客户记忆，并决定自动回复、保留草稿或转人工。

1. 核心组件

组件	默认地址 / 位置	作用
FastAPI 后端	http://127.0.0.1:8000	账号、会话、知识库、Agent 编排、记忆和后台管理
个人微信 Hook	127.0.0.1:30001	读取个人微信会话并发送消息
企业微信桥	127.0.0.1:8752	注入指定企微版本，读取历史并收发消息
桌面工作台	窗口程序	客服接待、记忆、群发、实例和运维操作
本地记忆服务	http://127.0.0.1:8888	长期记忆提取、合并、向量检索和治理
本地数据	acs.db、mem\data	业务数据、知识向量、记忆索引和评测结果

2. 一条客户消息如何处理

步骤	处理内容
1. 接收过滤	只接收允许的渠道、私聊 / 群聊和已选择会话；重复消息按来源 ID 去重。
2. 上下文整理	读取同一客户最近已完成、且客户确实收到过的对话；草稿和发送失败内容不会伪装成历史。
3. 意图路由	意图识别模块在售后知识库、闲聊、人工三条路线中只选一条，并记录 reason 与 summary。
4. 证据与记忆	业务问题只用 RAG 知识库；关系、偏好、情绪和跟进上下文可按语义召回长期记忆。
5. 安全检查	无知识证据、出现未被支持的数字 / 政策 / 库存 / 承诺、要求真实操作或模型异常时转人工。
6. 投递	auto_send=true 时自动发送；关闭时生成 AI 草稿，由客服确认。投递状态会记录并支持恢复。

3. 三类信息边界

信息源	适合保存 / 回答	不应承担
知识库 RAG	价格、政策、库存、物流、时效、售后规则、标准答复	客户个人偏好和关系连续性
客户长期记忆	称呼、偏好、需求、承诺、情绪、跟进背景	价格、库存、政策、时效或可执行指令
当前对话	本轮诉求、上下文指代、客户连续发送的消息批次	未经确认的长期业务事实

冲突处理原则

业务事实以知识库为准；记忆只帮助理解客户。记忆文本中的任何命令都按普通数据处理，不会被执行。

二 安装、首次启动与日常启动

1. 运行要求

- Windows 10 / 11 64 位。交付目录已包含 Python 3.11 便携运行环境，无需另装 Python。
- 个人微信需要 4.1.10.27；企业微信需要 5.0.3.6005。Hook 与版本强绑定。
- 真实 AI 需要可用的 DashScope 或 DeepSeek Key；演示模式不调用真实模型。

2. 获取系统的两种形式

形式	操作
安装器	双击 Setup.exe，按向导安装。安装完成后从桌面或开始菜单打开“AI客服”。
便携目录 / 压缩包	完整解压到固定目录，例如 D:\AI-Customer-Service；不要在压缩软件预览窗口或临时下载目录中运行。

3. 首次启动

1. 双击桌面“AI客服”快捷方式，或项目目录中的“启动AI客服.bat”。
2. 出现 Windows 管理员确认时选择“是”。该权限用于安装 / 降级兼容版本、禁用客户端自动更新和部署 Hook。
3. 启动器会从模板生成 .env、widget_config.yaml，并自动执行数据库迁移。
4. 按提示启动并登录个人微信；如使用企业微信，也完成企微登录。
5. 不要关闭黑色启动脚本窗口。脚本会等待 Hook 可读，随后启动后端、记忆服务和桌面工作台。
6. 工作台出现后，先打开“状态设置”，确认 backend 与 Hook 为 OK。

4. 入口与账号

入口	地址 / 操作
桌面工作台	启动后自动打开，是日常客服主界面
后台管理	http://127.0.0.1:8000/admin
健康检查	http://127.0.0.1:8000/health
默认演示账号	demo / demo12345，仅供初次验证，正式使用前必须修改

5. 日常启动

电脑和客户端版本未变化时，每天只需双击启动入口、登录微信 / 企业微信并等待工作台出现。客户端升级、收不到消息或 Hook 异常时，重新运行启动脚本让它重新检查并部署。

不要直接升级微信或企业微信

当前 Hook 只支持指定版本。客户端自动更新后可能无法读取消息；请通过“版本”页检查兼容性，并使用项目提供的降级流程。

三 配置说明

1. .env：后端、模型和记忆配置

配置项	说明
LLM_PROVIDER	fake 为演示；dashscope 为 Qwen 对话；deepseek 为 DeepSeek 对话并复用 DashScope 向量。
DASHSCOPE_API_KEY	Qwen 对话或 text-embedding-v3 向量化所需。
DEEPSEEK_API_KEY / BASE / MODEL	DeepSeek 对话网关、模型名与地址。
LLM_EMBED_MODEL	知识库和记忆向量模型，当前模板为 text-embedding-v3。
LLM_EMBEDDING_DIMENSION	当前配置为 1024；更换维度后必须重建派生向量索引。
DEEPSEEK_THINKING	false 更适合低延迟客服；true 会启用更慢的思考模式。
AGENT_HISTORY_LIMIT	意图识别模块最多带入的近期历史消息数，模板为 12。
AGENT_MAX_TURNS	单次 Agent 编排允许的最大模型调用次数，模板为 4。
RAG_DISTANCE_CUTOFF	知识片段相关性边界；超过边界的片段不会作为售后回答证据。
记忆任务超时	控制工作台记忆长任务的最长等待时间。
在线召回超时	控制在线对话记忆召回的等待时间；超时会跳过记忆，不阻塞客服回复。
JWT_SECRET / BOOTSTRAP_TOKEN	正式使用前换成长随机值。
APP_ENV / FIELD_ENC_KEY	生产环境设置 APP_ENV=prod，并填写 base64 编码的 32 字节字段加密 Key。

2. widget_config.yaml：桌面工作台与发送配置

配置项	推荐值 / 作用
backend_base_url	http://127.0.0.1:8000，一般不改。
hook_base_url	http://127.0.0.1:30001，个人微信 Hook 地址。
auto_send	首次验收保持 false；确认回复正确后再改为 true。
poll_interval_s	轮询新消息间隔，模板为 0.75 秒。
send_delay_min_s / max_s	发送前随机延迟，降低连续机械发送风险。
rate_per_min / daily_limit	每分钟和每日发送限制；只在明确理解风险后调整。
notifications	分别控制待人工通知、AI 已处理通知、是否自动打开工作台与提醒冷却。
scope.private_mode	selected 为仅接待会话页已勾选客户；all 为全部私聊。推荐 selected。
scope.allow_group / group_trigger	是否接待群聊及触发方式，默认关闭群聊。
allowlist / blocklist	联系人、群聊和会话级白名单 / 黑名单。

3. 企业微信配置

wecom_hook_config.yaml 通常由启动器自动生成。self_id 可留空，系统会从本地会话识别账号；strict_version 必须保持 true；auto_history_sync 默认 false，避免未经隐私审查的企业微信历史自动写入知识库。

修改配置后的生效方式
保存配置后重新运行启动入口。不要把 .env、真实 Key、客户数据或生产配置发给无关人员。

四 意图识别与 Agent 路由

当前系统不是多个独立 Agent 自由协作，而是由意图识别模块判断本轮消息批次的意图，再通过 Handoff 选择一个专业处理路径。意图识别模块不能直接回答客户。

1. 三条路由

路由	识别范围	处理结果
售后知识库 Agent	商品、购买、订单、物流、发票、退换货规则、维修、保修、投诉等业务事实	按当前租户检索 RAG；只回答有证据内容。无证据或需要操作时转人工。
闲聊 Agent	纯问候、感谢、情绪表达、兴趣爱好、生活分享，且不包含业务事实诉求	可结合相关长期记忆自然回应，但不得夹带价格、政策、库存、时效或承诺。
人工 Agent	明确要求真人、要求退款 / 改订单 / 发货 / 转账等真实操作、表达含混、信息不足或高风险	生成固定转人工通知，进入“待人工”队列。

2. 路由示例

客户消息	预期路由	原因
“这个商品支持七天无理由吗？”	售后知识库	需要店铺退货政策证据

客户消息	预期路由	原因
“谢谢你，今天心情好多了”	闲聊	只涉及感谢和情绪
“帮我把订单地址改一下”	人工	需要执行真实业务操作
“物流还没到，我很生气”	售后知识库	虽然有情绪，但包含物流事实诉求
“你记得我家猫叫什么吗？”	闲聊 + 记忆召回	可从当前联系人相关记忆中寻找名字

3. 上下文与可审计性

- 同一客户连续发送的多条当前消息作为一个批次整体识别，避免只看最后一句。
- 更早的历史只用于理解指代和上下文，不会把旧需求重新当作本轮任务。
- 每次 Handoff 都提交结构化 reason 与 summary，便于后续诊断路由原因。
- 只有客户确实收到过的已投递回复才进入后续 Agent 历史；草稿、失败和旧转人工提示会被过滤。

4. 失败关闭策略

- fake 演示模型不支持工具调用，因此不会自动路由回答，只会安全转人工。
- 意图识别模块未选择 Handoff、模型异常、知识库无有效命中或回答添加了知识库没有的数字 / 政策 / 承诺时，均转人工。
- 售后 Agent 只能回答问题，不能执行退款、发货、改地址、改订单或转账。

容易混淆的概念
“意图识别”决定这轮由谁处理；“知识库检索”寻找业务证据；“记忆召回”只补充当前客户的关系和偏好上下文。三者不是同一个功能。

五 知识库与可信业务回答

1. 知识库适合存什么

知识库是业务事实的唯一自动回答依据。建议维护营业时间、地址、联系方式、配送范围、价格规则、库存说明、发票、退换货、维修、保修、投诉流程、产品介绍和常见 FAQ。内容应清晰、可复用、已审核，并标明适用条件。

2. 后台维护

1. 打开 <http://127.0.0.1:8000/admin> 并登录。
2. 进入“知识库”，新增文字文档或上传支持的文件。
3. 检查标题、正文和适用范围；过期内容及时删除或替换。
4. 用测试账号发送真实问题，确认回答只使用知识库已有内容。

3. 从对话选择性反哺

企业微信历史自动写入知识库默认关闭。需要沉淀客服经验时，在“会话中心”选择一个客户，点击“总结并更新知识库 / 话术库”，阅读确认提示后再写入。只写入客服已经验证的业务事实和标准答复；私人聊天、临时承诺、噪声和客户个人信息不要入库。

4. 批量数据集导入

dataset/*.json 可保存人工审阅的问答或正文。推荐先进行只读预检：

```
& .\runtime\python\python.exe .\scripts\import_kb_dataset.py --dataset .\dataset
```

确认标题、文档数和字符数正确，备份 acs.db 后再追加：

```
& .\runtime\python\python.exe .\scripts\import_kb_dataset.py --dataset .\dataset --apply
```

支持 documents 列表、单个 {title, content} 文档、问答 qa 数组和 LoCoMo 风格 qa。只有完整 question 与 answer 会成为知识库内容；评测字段不会自动成为客服事实。

5. 回答安全

- 只回答检索到且达到相关性阈值的知识片段。
- 回答中出现知识库没有的数字、价格、日期、政策、库存、时效或承诺会被判为不可靠并转人工。
- 知识库只部分覆盖问题时，只回答有证据的部分。
- 同一租户标题重复的导入文档默认跳过；删除知识文档会同步删除向量片段。

知识库写作原则

不要写“尽量”“一般”“通常可以”等模糊承诺。用明确条件、范围和例外写标准答复；无法确认的内容交给人工。

六 客户长期记忆

系统使用项目内置的本地记忆服务维护原子长期记忆，再由这些记忆形成可读客户画像。它不再依赖每轮覆盖一段旧摘要，而是保留事实、偏好、需求、承诺和备注，并支持语义检索、更新、冲突治理与删除同步。

1. 记忆对话：从真实聊天提取

- 进入“记忆对话”，选择个人微信或企业微信渠道。
- 刷新真实会话，选择好友或群聊，并审阅要处理的消息。群聊按群 ID 隔离，同时保留真实发言人。
- 选择合适的最近消息范围，点击“提取长期记忆”。
- 确认后由 DeepSeek / DashScope 完成提取与向量化。该操作不会发送微信消息。
- 重复提取只处理上次游标之后的新消息，避免重复沉淀。

2. 长期记忆：画像与人工确认

- 查看已形成长期记忆的好友、摘要、画像标签、同步状态和原子记忆。
- 记忆类型包括事实、偏好、需求、承诺和备注；旧 profile 只作为兼容项，不再是唯一事实源。
- 客服可人工新增一条已确认记忆并设置重要度，系统会同步到记忆服务并更新画像。

3. 记忆召回：验证自动回复会看到什么

- 先选择已形成记忆的会话，再输入一条模拟的客户当前消息。
- 页面只检索相关记忆，不调用客服模型、不生成客服回复、也不发送消息。
- 结果展示类型、内容、总分、来源、更新时间与分数解释；没有相关结果时不会强行套用旧记忆。
- 在线主链路最多召回当前租户、渠道和联系人范围内的相关记忆，并有短超时保护。

4. 记忆治理：修订、置顶与删除

- 按客户 ID、内容、类型、来源、重要度、置顶和治理信号搜索审阅。
- 可新增、编辑、切换置顶、单条删除，或全选当前列表后批量删除。

- 删除长期记忆时会同步删除记忆服务中的对应项，避免下一次同步后“复活”。
- 可查看 ADD / UPDATE / DELETE / NOOP 等语义治理决策和单条记忆的治理轨迹；清理决策审计记录不会删除长期记忆。

5. 隔离、隐私与外部调用

项目	实际行为
数据位置	业务记录在 acs.db；记忆向量数据在本机 mem\data，不使用云端记忆存储。
隔离范围	按当前登录租户、渠道和联系人隔离；群聊使用独立群作用域。
模型调用	提取和向量化仍会调用 .env 配置的 DeepSeek / DashScope 等模型服务。
在线降级	记忆召回超时或失败时跳过记忆继续处理，不阻塞客服主链路。
业务边界	记忆不能作为价格、库存、政策、时效、承诺或真实操作依据。

七 桌面工作台全部页面

当前工作台按“客户服务、记忆、营销触达、运维、模型网关”分组。顶部实时显示待人工数量、服务渠道数、AI 服务状态和回复模式。

分组 / 页面	主要功能
客户服务 / 会话中心	切换渠道、查看真实本机历史、选中接待客户、查看消息来源和投递状态、手动发送、切换 AI 托管、打开知识库后台、总结对话反哺知识库。
客户服务 / 待人工	集中查看需要人工介入的消息，回复并结束，或标记忽略。连续待人工消息会按客户合并提醒。
记忆 / 记忆对话	从真实好友或群聊中审阅并增量提取长期记忆。
记忆 / 长期记忆	查看画像和原子记忆，人工新增已确认记忆。
记忆 / 记忆召回	按好友隔离模拟语义召回，查看分数、来源和解释；不生成回复。
记忆 / 记忆治理	搜索、修订、置顶、批量删除记忆，查看语义治理决策和轨迹。
营销触达 / 群发	AI 帮写、昵称 / 备注变量、选择好友、立即或定时发送、停止、续发和失败重试。
营销触达 / 群发任务	查看任务状态、文案、收件人明细、失败项和处理进度。
运维 / 状态设置	查看版本、Hook、后端、wxid、今日收发；控制自动发送、私聊 / 群聊、选择性接待、通知和每日上限。
运维 / 实例	新建微信 / 企微实例，查看平台、状态、进程内存，逐实例开关 AI 接管并跳转会话。
运维 / 版本	检查微信 / 企微版本与注入兼容性；必要时执行强制降级。
运维 / Worker 任务	查看画像更新、记忆召回和诊断任务的状态、耗时、结果；删除的是任务记录，不会取消运行中的任务。
运维 / 数据浏览	按租户白名单只读浏览会话、消息、长期记忆和知识文档；可选择删除，不能执行任意 SQL。
运维 / 功能测试	运行数据库、模型、记忆引擎等核心检查；LoCoMo 公开集评测属于功能实验，不代表真实客户效果。

分组 / 页面	主要功能
模型网关	脱敏显示提供商、对话模型、向量模型、维度、深度思考和运行模式；密钥始终隐藏。

会话中心的重要开关

- “接待此客户” 控制未来消息是否进入 AI 和后台记录。推荐只接待明确勾选的客户。
- “AI 托管” 关闭后，该会话完全由人工处理。
- auto_send=false 时，知识库可回答的内容显示为 “AI 草稿” ，不会自动发出。
- 聊天气泡区分客户、AI 自动回复、人工回复和群发来源；投递失败不会记作已送达。
- 双击客户会话可查看客户画像；画像随已确认长期记忆更新。

八 渠道、实例与版本管理

1. 个人微信

- 当前支持版本为 4.1.10.27，默认 Hook 地址为 127.0.0.1:30001。
- 启动器会检查 / 安装兼容版本、禁用自动更新、部署 Hook 并等待扫码登录。
- 收不到消息时先确认已登录，再重新运行启动器让它重新部署并检查 Hook。

2. 企业微信

- 当前支持版本为 5.0.3.6005，默认本机桥端口为 8752。
- wecom_hook_config.yaml 通常自动生成；账号 self_id 在运行时从本地会话识别。
- strict_version=true 会在版本不符时拒绝注入，避免错误偏移导致企微崩溃。
- 登录后可在 “会话中心” 顶部切换个人微信 / 企业微信。冷启动时会话可能短暂为空，稍等自动重试或手动刷新。

3. 多实例管理

“实例” 页可新建微信或企微实例，并查看账号、平台、连接状态和进程内存。每个实例可独立开关 AI 接管；InstanceSupervisor 负责监控和重连，不代表多个客服 Agent 互相协作。

4. 会话接待范围

范围	建议
私聊	启用 “仅接待会话页中已勾选的客户” 。未勾选会话不会进入 AI、后台记录或通知。
群聊	默认关闭。启用后还必须满足 at_me 等群触发规则和白名单 / 黑名单。
停止接待	取消 “接待此客户” 或关闭该会话 AI 托管；未来消息将按当前策略跳过。

版本页的强制降级

降级会关闭对应客户端，可能需要重新扫码，并要求管理员权限。执行前确认聊天数据已正常保存且没有正在进行的重要操作。

九 日常接待与人工协同

1. 推荐的每日操作顺序

- 1. 启动系统并登录需要接待的微信 / 企业微信。
- 2. 在“状态设置” 确认 backend、Hook 和 wxid 正常。
- 3. 进入“会话中心”，选择真正需要 AI 接待的客户并勾选“接待此客户”。
- 4. 在审阅模式下先检查 AI 草稿；确认知识库、语气和路由正确后再开启自动发送。
- 5. 定期处理“待人工”，人工回复后结束待办。
- 6. 需要长期连续性时，在“记忆对话” 审阅并提取，再到“长期记忆” 和“记忆召回” 核验。

2. 自动回复与草稿

条件	结果
auto_send=true 且可安全回答	自动发送给客户，AI 已处理默认静默。
auto_send=false 且可安全回答	生成 AI 草稿并留在待办，客服确认后人工发送。
无法安全回答 / 需要真实操作	进入待人工，按通知设置提醒。
同一客户连续待人工消息	合并为一个待办；通知在冷却时间内只显示一次。

3. 人工处理

- 在“待人工” 选择消息，输入回复并点击“回复并结束”；或确认无需回复后标记忽略。
- 人工回复会作为已完成对话进入后续上下文；固定转人工通知不会被误当成业务答案。
- 通知可分别控制待人工、AI 已处理和是否自动打开工作台。通常只开启待人工通知。

4. 消息可靠性

- 来源消息 ID 会被哈希后用于幂等去重，重复回调不会重复生成回复。
- 系统记录待投递、已认领、已送达、失败等状态；未送达内容不会进入 Agent 历史。
- 异常中断后会恢复未完成投递，减少重复生成和漏发。

首次上线建议

先保持 auto_send=false，并只选择一个安全测试客户。验证意图路由、知识证据、记忆关联、投递状态和转人工后，再逐步扩大接待范围。

十 群发与群发任务

1. 创建群发

- 1. 进入“群发”，编辑文案；可使用“AI 帮写”生成初稿。
- 2. 按需使用 {昵称}、{备注} 变量，检查每位收件人的预览。
- 3. 从好友库选择收件人；非好友会置灰，不能勾选。
- 4. 选择立即发送或定时发送。定时任务执行时本机必须开机且工作台运行。
- 5. 首次正式群发只选一个安全测试联系人，确认格式和渠道正确后再扩大范围。

2. 发送控制

- 发送过程遵守随机延迟、每分钟速率和每日上限。
- 可在发送中停止；停止后的任务可继续发送。
- 失败项会单独列出，可只重试失败对象，避免整批重复。
- “群发任务”页显示状态、文案、收件人明细、失败原因和处理进度。

3. 风险控制

风险	操作要求
发错人	先单人测试，确认好友库和账号渠道。
变量错误	检查昵称 / 备注为空时的实际文案。
重复发送	优先使用继续发送或重试失败项，不要重新创建整批任务。
账号风控	保持合理速率、随机延迟和每日上限；不要随意解除上限。
定时任务漏发	确保任务时间内电脑、客户端、Hook 和工作台持续在线。

群发与自动客服是两条独立链路

群发消息会标记来源，不当成 AI 自动回答。群发前的合规审核、客户授权和内容责任仍由运营人员承担。

十一 后台管理与运维工具

1. 后台管理页面

页面	功能
看板	查看数据概览和销售 / 成交等运营指标。
知识库	新增、上传和删除知识文档，维护 AI 业务事实。
机器人配置	设置语气档位和 persona 等回答风格。
会话记录	分页查看客户与系统对话，查看详情并标记成交。
标签	创建、删除、停用标签，并管理客户 AI 静默。
账号	新增和删除后台账号。

2. Worker 任务

显示画像更新、记忆召回和诊断等后台任务的任务 ID、类型、名称、状态、耗时、结果和开始时间。删除只清理任务记录，不会中止仍在运行的实际任务。

3. 数据浏览

仅允许浏览当前租户的会话、消息、长期记忆和知识文档，并限制每次加载数量；不开放任意 SQL。删除会话会同时删除其消息和成交记录；删除知识文档会删除关联向量片段，操作不可撤销。

4. 功能测试

- “系统检查” 执行数据库、模型与记忆引擎等核心健康检查。
- “LoCoMo 公开集评测” 用于验证记忆算法与运行环境，不代表真实客户记忆效果。
- 正式评测应先单 worker、小样本和 predict-only，确认模型、维度、collection 与数据目录后再扩大。

5. 模型网关

模型网关页只读展示当前提供商、对话模型、向量模型、向量维度、是否开启深度思考和运行模式。API Key 始终隐藏；配置不完整时页面会明确提示。

6. 独立检查记忆服务

正常使用请通过一键启动。如需确认本地记忆服务是否在线，可在 PowerShell 中运行：

```
Invoke-RestMethod http://127.0.0.1:8888/health
```

删除数据前

先在项目目录外备份 acs.db 和必要的 mem\data。数据浏览中的删除不可撤销，且可能级联删除消息、成交记录或向量片段。

十二 验收、排障、安全与卸载

1. 推荐的首次验收清单

- 已完整安装 / 解压到固定目录，并以管理员权限完成首次启动。
- 个人微信已登录；如需企微，企业微信也已登录且版本兼容。
- “状态设置” 中 backend、Hook 正常，工作台能看到会话。
- 保持 auto_send=false，只选择一个安全测试客户进行接待。
- 业务问题路由到售后知识库；问候 / 情绪路由到闲聊；真实操作请求进入待人工。
- 知识库问题生成的回答没有添加文档中不存在的数字、政策或承诺。
- 在“记忆对话” 提取测试聊天，在“长期记忆” 看到原子记忆和画像，在“记忆召回” 找到相关结果。
- 工作台能人工回复，投递状态正确，发送失败不会显示为已送达。
- 群发只对一个测试联系人验证，失败项可重试。
- 修改默认后台密码和生产密钥，确认备份方案后再开启自动发送。

2. 常见问题

现象	处理
双击启动没反应	确认已完整解压；右键以管理员身份运行；检查杀毒软件是否拦截本地脚本。
后台打不开	查看 logs\backend.err.log；确认 .env 存在且 8000 端口未被其他程序占用。
收不到微信消息	确认已登录且版本为 4.1.10.27；重启启动脚本重新部署 Hook；查看 logs。
企业微信会话为空	确认版本为 5.0.3.6005；冷启动稍等自动重试或点击刷新；检查版本阉提示。
AI 不自动发送	检查 auto_send、会话“接待此客户”、AI 托管、私聊 / 群聊范围和发送上限。
所有消息都转人工	fake 模式属于正常安全行为；真实路由需要支持 function calling 的 DashScope / DeepSeek 配置。
业务问题转人工	检查知识库是否有达到阈值的证据；补充经过审核的事实，不要降低安全边界来掩盖缺少知识。
记忆没有出现	确认记忆服务在线；在“记忆对话” 勾选含明确事实的消息并提取；检查模型 Key 和超时。
记忆召回为空	确认选择的是同一租户、渠道和联系人；问题与记忆无语义关联时为空属于正常。
生产密钥自检失败	APP_ENV=prod 时必须使用强随机 JWT_SECRET、BOOTSTRAP_TOKEN 和 FIELD_ENC_KEY。

3. 安全要求

- 不要外发 .env、API Key、生产配置、acs.db、mem\data、日志或客户聊天。
- 首次使用保持 auto_send=false；群发先单人验证；不要随意解除每日上限。
- 修改嵌入模型或向量维度前先备份并重建派生索引，不能直接混用旧向量。
- 正式环境修改默认后台密码，并使用强随机密钥和字段加密 Key。
- 记忆提取可能调用外部模型网关，敏感聊天必须先通过组织隐私审查。

4. 重要目录

文件 / 目录	说明
启动AI客服.bat / AI客服.lnk	一键启动入口
scripts\Start-AICustomerService.ps1	实际启动编排脚本
.env / widget_config.yaml	后端模型与桌面工作台配置
wecom_hook_config.yaml	企业微信 Hook 配置，通常自动生成
app / widget / alembic	后端、桌面工作台和数据库迁移
agents / mem	项目内置 Agent SDK 与记忆服务
runtime / assets / native	便携 Python、客户端资产和 Hook 原生组件
acs.db	本地业务数据库，迁移、替换或删除前必须备份
mem\data	本地记忆向量数据和评测结果
logs	排查问题时优先查看

5. 卸载

安装器版本可在 Windows “设置 → 应用” 中卸载。便携版关闭工作台、启动脚本、微信和企业微信后，可删除项目目录；卸载程序通常不会主动删除已积累的 acs.db 与记忆数据。若需彻底清理，请先按组织要求导出或安全销毁数据，再删除安装目录。

交付人员一句话说明

以后双击“AI客服”并登录微信，系统会自动启动后端、记忆服务和工作台。先只选择测试客户并保持审阅模式；确认意图路由、知识库回答、记忆召回和人工转接都正确后，再开启自动发送。

文档结束